

NYCU Generative Artificial Intelligence Homework 4 - Crawling Releases

繳交期限: 2026/05/19 23:59

TA Hour: 週四 15:00~16:00

TA Email: dragonfruit11311@gmail.com


Outline

- 目標
 - Crawl
 - Push
 - Popular
 - Keyword
 - 繳交內容
- 配分
 - 對比工具
 - Note

目標

爬PTT Stock板2025一整年的文章，2025年的第一篇文章為 [心得] 2024年報

<https://www.ptt.cc/bbs/Stock/M.1735671336.A.BD5.html>。



需要繳交一份 python 腳本，檔名為 {student_id}.py，支援四種命令列介面功能：

1.Crawl

2.Push

3.Popular

4.Keyword

NYCU

Crawl

功能：

- 爬2025年所有Stock版文章。
- 忽略標題含有 [公告] 和 Fw:[公告] 的文章。
- 忽略缺少標題、標題是空字串的文章。
- 忽略沒有對應網址的文章。
- 列表頁面顯示的文章標題可能會和內文顯示的標題有差異，在
這裡以列表頁面的為準。

Crawl

- 格式：`$ python {student_id}.py crawl`
- 範例：`$ python 414581006.py crawl`
- 輸入：沒有輸入。
- 輸出：

格式說明：

➤ 在當前資料夾輸出兩個檔案：

1. **articles.jsonl** -> 包含所有文章。
2. **popular_articles.jsonl** -> 包含所有推爆的文章。

Crawl

- 兩個檔案的格式均為 jsonlines，其中每一個 json 代表一篇文章的資訊，文章不需要按照日期排序，其json格式為：
{"date": "{文章日期}", "title": "{文章標題}", "url": "{文章網址}"}
- 範例 articles.jsonl 的前幾行：

```
{"date": "0101", "title": "[心得] 2024年報", "url": "https://www.ptt.cc/bbs/Stock/M.1735671336.A.BD5.html"}  
{"date": "0101", "title": "[心得] 延畢大學生 2024年結算", "url": "https://www.ptt.cc/bbs/Stock/M.1735675922.A.CBE.html"}  
{"date": "0101", "title": "[心得] 2024年報(太早降槓桿,重新存股TQQQ)", "url": "https://www.ptt.cc/bbs/Stock/M.1735688976.A.F82.html"}  
{"date": "0101", "title": "[心得] 2024年報", "url": "https://www.ptt.cc/bbs/Stock/M.1735689603.A.92C.html"}
```

注意事項

- 文章順序不會影響評分。
- 文章的 url 請以 https:// 開頭。
- 第一個測試指令一定是 crawl，後續所有測試都可以讀取 articles.jsonl 和 popular_articles.jsonl。

Crawl

- 日期、標題、推文減噓文和URL：

批踢踢實業坊 > 看板 Stock		聯絡資訊 關於我們	
看板	精華區	最舊	上頁 下頁 最新
52 [新聞] 2025年封關 國內股民平均每人大概賺85.5萬	Su22		12/31 ...
7 [心得] 2025 30歲奈米戶年報	chun0107		12/31 ...
忽略公告 67 [公告] 五、四、三、二、一、新年水桶快樂！	BlueBird5566	M	1/01 ...
5 [心得] 2025先衰後盛 反敗為勝	TrRosenthal		1/01 ...
推文數減 噓文數 10 [心得] 2025年報	kjshu	日期	1/01 ...
12 [心得] 2025 台股仔跟期貨心得	bookway		1/01 ...
標題 5 [心得] 2025 起飛年報	benjo		1/01 ...
7 [心得] 2025奈米橫桿年報	MindYours		1/01 ...

URL: <https://www.ptt.cc/bbs/Stock/M.1767206436.A.75C.html>

批踢踢實業坊 > 看板 Stock

作者 MindYours (狐)
標題 [心得] 2025奈米橫桿年報
時間 Thu Jan 1 02:40:34 2026


手機發文排版醜啊請見諒

第一次寫年報，想說留個紀念年底可以回來看：
今年初轉職成功，在4月關稅帝君以前讀到周教授跟大仁哥有關大盤跟正二的書，還有生命週期投資法等等，決定整理股票資產，學習借貸並開始紀錄，以前都是聽明牌短線亂進出，輸多贏少...

先上我的每月月底紀錄表格圖：
<https://i.mopix.cc/061C&P.jpg>



返回看板



BASIC LAB


Crawl

推爆定義:

一篇文章被推時，文章前會顯示推文（低調推除外）的次數，但如果被噓文時，會抵銷掉推文的次數，而推文-噓文大於100時，就會變成「推爆」的狀況。但進入爆的狀況之後，系統就不會再計算推文數，而是持續以100來計數，因此即使推文數遠超100，但這時有人噓文時，數字還是會恢復到99，這時要再有人推才會再變成爆的狀態。（或可稱為「再推爆一次」）

批踢踢實業坊 - 看板 Stock		聯絡資訊 關於我們	
看板	精華區	最舊	最新
38	Re: [請益] 台積電對於巴菲特的價值投資？ LINPINPARK	1/06	...
8	[新聞] 焦點股》國巨*：磁珠產品漲價 價量齊揚 YU1225	1/06	...
爆	[情報] 115年01月06日 三大法人買賣金額統計表 coconing	1/06	...
9	[情報] 2026年前三個開盤日都創歷史新高 winall	1/06	...
28	[新聞] 華邦電創新高！藝人香蕉「跌到13元也沒賣」 kof70380	1/06	...
49	[新聞] 全台攤954店美味登！揚泰2025年營收突破3 burlroof	1/06	...
99	[情報] 2408 南亞科 12月營收 Y+444.87% m+18.18% MOMO0478	1/06	...
14	[情報] 3324 雙鴻 114年12月營收 rz2x	1/06	...
6	[情報] 3264 欣銓自結114/11月單月EPS 0.63		

NYCU



BASIC LAB


Push

功能：

找出在 {start_date} (含) 跟 {end_date} (含) 之間的以下資訊：

- 推文和噓文兩種各自的總數。
- 推文最多次的前10名 user_id。
- 噓文最多次的前10名 user_id。

NYCU



Push

- 格式：`$ python {student_id}.py push {start_date} {end_date}`
- 範例：`$ python 414581006.py push 0304 1231`
- 輸入：`{start_date}`、`{end_date}` -> 格式為MMDD，例如3/4為 0304，12/31為 1231。
- 輸出：
 - 在當前資料夾輸出一個json檔，檔名請按照以下格式：
 1. `push_{start_date}_{end_date}.json`
 2. 範例：`push_0304_1231.json`

Push

- json格式：

```
{
  "push": {
    "total": {推文總數},
    "top10": [
      {"user_id": "{user id}", "count": {推文數}},
      {"user_id": "{user id}", "count": {推文數}},
      ...
    ]
  },
  "boo": {
    "total": {噓文總數},
    "top10": [
      {"user_id": "{user id}", "count": {噓文數}},
      {"user_id": "{user id}", "count": {噓文數}},
      ...
    ]
  }
}
```

- 輸出範例：

```
{
  "push": {
    "total": 1040,
    "top10": [
      {"user_id": "maxxxxxx", "count": 6},
      {"user_id": "Krishna", "count": 6},
      {"user_id": "yggyygy", "count": 5},
      {"user_id": "tyrande", "count": 5},
      {"user_id": "monarch0301", "count": 5},
      {"user_id": "johnwu", "count": 5},
      {"user_id": "cityhunter04", "count": 5},
      {"user_id": "adamlovedogc", "count": 5},
      {"user_id": "abellea85209", "count": 5},
      {"user_id": "Lailungsheng", "count": 5}
    ]
  },
  "boo": {
    "total": 247,
    "top10": [
      {"user_id": "QVQ9487", "count": 6},
      {"user_id": "thec1gy2001", "count": 4},
      {"user_id": "cczoz", "count": 4},
      {"user_id": "zss40401", "count": 3},
      {"user_id": "cityhunter04", "count": 3},
      {"user_id": "yushenglu", "count": 2},
      {"user_id": "un94su3", "count": 2},
      {"user_id": "srmember", "count": 2},
      {"user_id": "sion1993", "count": 2},
      {"user_id": "saw6904", "count": 2}
    ]
  }
}
```

Push

- 推文、噓文及中立留言

批踢踢實業坊 > 看板 Stock 聯絡資訊 關於我們



我沒有說賭不好 可是你不要騙自己在投資嘛

噓 madeinheaven: 才84萬 ==	01/06 15:44
→ oox123 : 怎麼不問星宇? 中立留言	01/06 15:47
推 ss425727100 : 所以大家趕快撿破爛 買那種破底破底在破底的	01/06 15:49
→ fallinlove15: 獲利六位數在股版連提鞋的資格都沒有吧	01/06 15:50
→ ahg : 蕉點到了	01/06 15:51
推 superminshin: 蕉你作股票 推文	01/06 15:56
推 SphereDavid : 糕味濃	01/06 15:57
噓 vvnews : 25跌到13不就凹單仔 噓文	01/06 15:58
推 Feltonee : 一堆眼紅的在崩潰笑死	01/06 15:59
噓 b551122 : ==這誰	01/06 15:59
→ learnbao : 他怎麼不說星宇航空	01/06 16:02

Popular

功能：

找出在 {start_date} (含) 跟 {end_date} (含) 之間的以下資訊：

- 推爆的文章數量。
- 推爆文章中的所有圖片URL，包括內文和留言中的圖片URL。
- 圖片URL定義：開頭必須是 http:// 或 https://，並且要以 .jpg、.jpeg、.png、.gif 為副檔名結尾，副檔名不限大小寫。

批踢踢實業坊 - 看板 Stock

→ mopigou : 川普第一屆就示範過拉, 就知道他會taco
 噁 loopdiuretic : 還沒走出來喔?
 推 f204137 : <http://imgpo1.com/i/UARXBM.jpg> 1股不賣 百%自來
 留言內圖片URL: <http://imgpo1.com/i/UARXBM.jpg>

重新查詢

筆數:3(頁次 1/1)


交易日期	股名	種類	股數	成交價	投資成本	現價	帳面收入	損益	損益率
2025/04/07	2330 台積電	現股	2	848	1,697	1,705	3,399	1,702	100.29%
2025/04/08	2330 台積電	現股	3	814	2,443	1,705	5,099	2,656	108.72%
2025/04/09	2330 台積電	現股	4	792	3,169	1,705	6,799	3,630	114.55%

推 baw88 : 你有內線消息就可以
 推 Giusi1999 : 林北聽多囉
 返回看板

批踢踢實業坊 - 看板 Stock

作者 win8719 (win8719)
 標題 Re: [新聞] 台股站上3萬點高檔 散戶：沒台積電根本沒
 時間 Mon Jan 5 14:37:46 2026

我滿佩服聯合可以找到這群人的
 還是這是記者自己幻想出來的小說阿
 那就用數據說話
<https://i.mecc.com.tw/Uit2IKYu.jpg> 內文中圖片URL




大盤和隆台積電(000-)

成交額: 1M 4,188.51 1M 4,748.12 1M 4,584.1

返回看板

Popular

- 格式：`$ python {student_id}.py popular {start_date} {end_date}`
- 範例：`$ python 414581006.py popular 0304 1231`
- 輸入：`{start_date}`、`{end_date}` -> 格式均為MMDD，例如3/4為 0304，12/31為 1231。
- 輸出：
 - 在當前資料夾輸出一個json檔，檔名請按照以下格式：
 1. `popular_{start_date}_{end_date}.json`
 2. 範例：`popular_0304_1231.json`



Popular

- json格式：

```
{
  "number_of_popular_articles": {推爆數},
  "image_urls": [
    "{url_1}",
    "{url_2}",
    ...
  ]
}
```

注意事項

- 評分時不比較順序。不用刪除重複的URL。

- 輸出範例：

```
{
  "number_of_popular_articles": 2,
  "image_urls": [
    "https://i.imgur.com/UDJQEyi.jpg",
    "https://i.imgur.com/jUrvWQM.jpg",
    "https://i.imgur.com/1U5JTIT.jpg",
    "http://i.imgur.com/spn4dNg.jpg",
    ...
  ]
}
```

Keyword


功能：

找出在 {start_date} (含) 和 {end_date} (含) 之間內文包含 {keyword} 的文章，並統計這些文章的以下資訊：

- 文章中的所有圖片URL，包括內文和留言中的圖片URL。
- 圖片URL定義：開頭必須是 http:// 或 https://，並且要以 .jpg、.jpeg、.png、.gif 為副檔名結尾，副檔名不限大小寫。

內文範圍說明：

- 從「作者」(含)開始到綠色的「※發信站」(不含)之間，只要有出現 {keyword} 就算。
- 如果「※發信站」不存在，則忽略這篇文章。
- 內文標題和文章列表顯示的標題可能不同，以內文為準。
- 內文出現的網址也在 keyword 匹配範圍內。



BASIC LAB

Keyword

- 內文範圍

[情報] 3443 創意 12月營收 - 看

https://www.ptt.cc/bbs/Stock/M.1767593788.A.353.html

批踢踢實業坊 > 看板 Stock

作者: suntw (眼)
標題: [情報] 3443 創意 12月營收
時間: Mon Jan 5 14:16:25 2026

https://mops.twse.com.tw/mops/#/web/r05st10_ifrs

本資料由 (上市公司) 創意 公司提供
民國114年12月
單位: 新台幣仟元
項目: 營業收入淨額
本月: 4,747,837
去年同期: 2,702,478
增減金額: 2,045,359
增減百分比: 75.68
本年累計: 34,140,978
去年累計: 25,044,192
增減金額: 9,096,786
增減百分比: 36.32
備註/營收變化原因說明: 主要為晶圓產品(Wafer production)增加
MOM+20.62% YOY+75.68%

9月開始連續4個月創歷史新高

--


* 發信站: 批踢踢實業坊(PTT.cc), 來自: 175.182.144.38 (臺灣)
* 文章網址: https://www.ptt.cc/bbs/Stock/M.1767593788.A.353.html

返回看板

NYCU

Keyword

- 格式：`$ python {student_id}.py keyword {start_date} {end_date} {keyword}`
- 範例：`$ python 414581006.py keyword 0304 1231 台股`
- 輸入：
 1. {keyword} -> 保證不包含空白字元 (例如 space、tab ...)
 2. {start_date}、{end_date} -> 日期格式均為MMDD，例如3/4為0304，12/31為1231。
- 輸出：
 - 在當前資料夾輸出一個json檔，檔名請按照以下格式：
 1. `keyword_{start_date}_{end_date}_{keyword}.json`
 2. 範例：`keyword_0304_1231_台股.json`



Keyword

- json格式：

```
{  
    "image_urls": [  
        "{url_1}",  
        "{url_2}",  
        ...  
    ]  
}
```

- 注意事項

評分時不比較順序。不用刪除重複的URL。

- 輸出範例：

```
{  
    "image_urls": [  
        "https://i.imgur.com/LNFIMk9.jpg",  
        "https://i.imgur.com/KpWP9Dm.jpg",  
        "http://i.imgur.com/A2LqXBB.jpg",  
        ...  
    ]  
}
```

繳交內容

只能繳交一個 .py 檔，名稱為 {student_id}.py，請將 {student_id} 替換為你的學號。

測試環境：

- 作業系統：Ubuntu 24.04。
- Python 3.12.3 (Python 3.12.x 都相容)。
- 使用工程四館的獨立 IP 進行測試。
- 只能使用 Python 3.12.x 預設套件和右側套件，如果有需求可以和助教討論
- 如果繳交格式有誤但手動修正後可正常執行，最後成績 x0.8。如果無法執行，則視為沒有繳交。

```
beautifulsoup4==4.13.4  
click==8.1.8  
html5lib==1.1  
httpx==0.28.1  
lxml==5.3.2  
pandas==2.2.3  
pyquery==2.0.1  
requests==2.32.3  
scrapy==2.12.0  
tqdm==4.67.1
```

評分

- 對 {student_id}.py 進行測試，除了 Crawl 以外，每種功能測試 5 組參數，每組參數的測試結果正確可得 5 分。
- 配分：

功能	配分	時限 (一組參數)	備註
Crawl	25%	20分鐘	
Push	25%	10分鐘	單筆參數日期跨度最多92天
Popular	25%	10分鐘	單筆參數日期跨度最多92天
Keyword	25%	10分鐘	單筆參數日期跨度最多92天

- 程式執行超過時限會被強制 kill。

比對工具

壓縮檔 `hw4.zip` 中提供一個檢測腳本 `eval.py` 和一個資料夾 `2025_answer` 含有 2025 年的部分測試答案，可以從檔案名稱看出測試參數。假設你的輸出檔案都存在資料夾 `outputs` 中，資料夾結構如範例如下：

- 可以用以下指令測試正確性：

```
python eval.py 2025_answer outputs
```

```
./
├── 2025_answer
│   ├── articles.jsonl
│   ├── keyword_0601_0631_台股.json
│   ├── keyword_0701_0731_配息.json
│   ├── keyword_0815_0910_台積電.json
│   └── ...
├── outputs
│   ├── articles.jsonl
│   ├── keyword_0601_0631_台股.json
│   ├── keyword_0701_0731_配息.json
│   ├── keyword_0815_0910_台積電.json
│   └── ...
└── eval.py
```

Note

- Crawl 建議用 append 模式開檔，不斷寫入已經爬取的文章資訊，避免遇到 Exception 時完全沒有儲存結果。
- 多行程 (multi-process) 請用 `os.cpu_count()` 取得當前邏輯處理器數量，並對行程數適當調整
- 測試結果可能因為有人推文、噓文、刪除文章等行為隨著時間改變，因此：
 - 2025_answer 在你測試的時候不一定會是正確答案
 - 作業批改時，答案生成和測試會盡量在短時間內完成。



Thank you for listening!



NYC